

Previsão de Temperatura e de Chuva na Austrália: Séries Temporais e Classificação Supervisionada no Conjunto *Rain in Australia*

João Pedro Dias de Carvalho

Programa de Pós-Graduação em Ciências Computacionais e Modelagem Matemática (CompMat)

Universidade do Estado do Rio de Janeiro (UERJ)

Disciplina: Aprendizado de Máquina em Sistemas Dinâmicos — Prof. Americo Cunha

Resumo—Este trabalho aplica técnicas de regressão e de classificação a dados meteorológicos reais: cerca de 145 mil observações diárias de 49 estações australianas (2007–2017), disponíveis no Kaggle. Na regressão, previ a temperatura máxima média semanal de Sydney com quatro modelos supervisionados de séries temporais: SARIMAX com harmônicos de Fourier e erros ARMA, Prophet, decomposição STL seguida de ARIMA e a média simples dos três. Os hiperparâmetros foram escolhidos por AIC ou validação e os modelos foram avaliados em 78 semanas futuras, em previsão de longo prazo e de um passo à frente, além de um *backtest* com origem móvel. O SARIMAX obteve o menor erro (RMSE de 1,65 °C no longo prazo e 1,59 °C um passo à frente, 22% abaixo do modelo ingênuo) e resíduos sem autocorrelação detectável, mas o teste de Diebold–Mariano não o distingue do Prophet nem da combinação. Na classificação, previ se choveria no dia seguinte (22% de dias positivos) com regressão logística (um GLM), KNN, Random Forest e LightGBM, após engenharia de atributos que inclui codificação circular do vento, tendência barométrica e indicadores de ausência. Com validação cruzada estratificada, limiar escolhido fora da amostra e teste temporal em 2016–2017, o LightGBM foi o melhor (ROC-AUC de 0,889, PR-AUC de 0,752 e F1 de 0,674), seguido pela Random Forest. A umidade às 15h, a rajada de vento e a variação da pressão foram as variáveis mais informativas. Discuto as premissas dos modelos, a calibração das probabilidades e as limitações para uso operacional.

Palavras-chave—séries temporais, SARIMAX, Prophet, STL, combinação de previsões, classificação desbalanceada, regressão logística, gradient boosting, meteorologia.

I. INTRODUÇÃO E CONTEXTUALIZAÇÃO

Prever o tempo é um problema clássico de sistemas dinâmicos: a atmosfera evolui segundo equações não lineares e sensíveis às condições iniciais [1], e as observações em superfície (temperatura, pressão, umidade, vento) são projeções ruidosas e parciais desse estado. Ainda assim, padrões estatísticos robustos, como o ciclo anual de temperatura ou a queda de pressão que antecede frentes frias, permitem construir previsores úteis, baseados em dados, para agricultura, energia, defesa civil e saúde pública. A temperatura semanal, por exemplo, orienta o planejamento da demanda de energia e de alertas de calor, e a probabilidade de chuva no dia seguinte afeta a logística e o manejo de recursos hídricos.

Este trabalho usa o conjunto *Rain in Australia* [2], derivado das observações diárias do *Bureau of Meteorology* (BoM) australiano [3] e originalmente distribuído com o pacote

Tabela I
ESTATÍSTICAS DESCRITIVAS DAS VARIÁVEIS NUMÉRICAS (BASE COMPLETA).

	Média	DP	Mín	Mediana	Máx	Assimetria	Faltantes (%)
MinTemp	12,2	6,4	−8,5	12,0	33,9	0,0	1,0
MaxTemp	23,2	7,1	−4,8	22,6	48,1	0,2	0,9
Rainfall	2,4	8,5	0,0	0,0	371,0	9,8	2,2
Evaporation	5,5	4,2	0,0	4,8	145,0	3,8	43,2
Sunshine	7,6	3,8	0,0	8,4	14,5	−0,5	48,0
WindGustSpeed	40,0	13,6	6,0	39,0	135,0	0,9	7,1
WindSpeed9am	14,0	8,9	0,0	13,0	130,0	0,8	1,2
WindSpeed3pm	18,7	8,8	0,0	19,0	87,0	0,6	2,1
Humidity9am	68,9	19,0	0,0	70,0	100,0	−0,5	1,8
Humidity3pm	51,5	20,8	0,0	52,0	100,0	0,0	3,1
Pressure9am	1017,6	7,1	980,5	1017,6	1041,0	−0,1	10,4
Pressure3pm	1015,3	7,0	977,1	1015,2	1039,6	−0,0	10,3
Cloud9am	4,4	2,9	0,0	5,0	9,0	−0,2	38,4
Cloud3pm	4,5	2,7	0,0	5,0	9,0	−0,2	40,8
Temp9am	17,0	6,5	−7,2	16,7	40,2	0,1	1,2
Temp3pm	21,7	6,9	−5,4	21,1	46,7	0,2	2,5

rattle [4]. Cada registro corresponde a um par (estação, dia) e contém 19 variáveis meteorológicas (16 numéricas e 3 direções de vento), além da indicação de chuva no próprio dia (*RainToday*) e no dia seguinte (*RainTomorrow*). Formulei dois problemas:

- 1) **Regressão (série temporal)**: prever a temperatura máxima média semanal de Sydney, com horizontes de uma a 78 semanas;
- 2) **Classificação (binária)**: prever se choverá mais de 1 mm nas 24h que terminam às 9h do dia seguinte (*RainTomorrow*) em qualquer uma das 49 estações.

O restante do texto descreve os dados e o pré-processamento (Seção II), a formulação dos modelos, os experimentos (Seção III) e a discussão (Seção IV). O código (Python) e um *notebook* executável acompanham este relatório.

II. METODOLOGIA E DADOS

A. Descrição do conjunto de dados

A base tem 145.460 linhas e 23 colunas (16 numéricas, 6 categóricas e a data), de 01/11/2007 a 25/06/2017. A Tabela I resume as variáveis numéricas. Cerca de 10,3% das células estão vazias e só 38,8% das linhas são completas.

B. Análise exploratória e pré-processamento

Dados ausentes. A Fig. 1 mostra que a ausência é, em grande parte, *estrutural*: 19 estações nunca mediram insolação

(Sunshine) e 16 nunca mediram evaporação. Como a ausência não é aleatória, descartar linhas eliminaria 61% dos dados e introduziria viés geográfico. Por isso, imputei a mediana *dentro* da *pipeline* de validação, o que evita vazamento de informação, e acrescentei indicadores binários de ausência. Removi apenas as 3.267 linhas (2,2%) sem o alvo.

Inconsistências. Verifiquei regras físicas e lógicas: duplicatas (estação, dia), $T_{\min} > T_{\max}$, umidade fora de $[0, 100]$, chuva negativa, coerência entre RainToday e $\text{Rainfall} > 1$ mm e a identidade $\text{RainTomorrow}(t) = \text{RainToday}(t+1)$. Todas foram satisfeitas, exceto três registros de nebulosidade igual a 9, código de “céu obstruído” e não uma medida em oitavos, que foram convertidos em ausentes. A última identidade confirma a definição do alvo e reforça que nenhuma informação de $t+1$ pode entrar como preditor. Há, porém, uma sobreposição temporal própria do conjunto: RainToday mede a chuva nas 24h até as 9h [4], de modo que o alvo cobre o intervalo das 9h de t às 9h de $t+1$. As medições das 15h (Humidity3pm , Pressure3pm , Cloud3pm , Temp3pm) e a rajada máxima até a meia-noite (WindGustSpeed) caem dentro dessa janela. Não há vazamento, pois esses valores já são conhecidos ao fim do dia t , mas o horizonte efetivo da previsão é de cerca de 9 a 18h, e parte da tarefa é de *nowcasting*. Há ainda 4.112 dias de calendário sem registro em algumas estações, o que foi levado em conta ao construir variáveis defasadas.

Distribuições e outliers. Rainfall (assimetria de 9,8) e Evaporation (3,8) têm caudas longas à direita. Pela regra de Tukey ($1,5 \times \text{IQR}$) [5], 18% dos dias têm chuva “atípica”, porque o primeiro quartil e a mediana são zero e o IQR é minúsculo. Esses extremos são eventos reais, justamente os de interesse, e não erros. Por isso, não os removi: apliquei $\log(1+x)$ e preferi modelos robustos (árvores) ou padronizados (z-score). Os histogramas de todas as variáveis estão no *notebook*.

Correlação e alvo. Há blocos fortemente colineares, como $\text{Pressure9am} - \text{Pressure3pm}$ ($r = 0,96$) e $\text{MaxTemp} - \text{Temp3pm}$ ($r = 0,98$) (Fig. 2). O alvo é desbalanceado (22,4% de “Sim”, razão de 3,5:1) e varia muito entre estações, de 7% em Woomera, no deserto, a 37% em Portland, e entre meses, com pico no inverno austral (Fig. 3).

Engenharia de atributos (classificação). A partir das variáveis brutas, criei 41 preditores, todos calculados apenas com informação disponível até o dia t :

- *transformações*: $\log(1+x)$ da chuva e da evaporação;
- *dinâmica intradiária*: amplitude térmica e diferenças 15h–9h de temperatura, pressão, umidade e nebulosidade;
- *dinâmica de 24h*: variação de pressão (tendência barométrica), de umidade e de temperatura em relação ao dia anterior na mesma estação, além de RainYesterday ;
- *direções do vento* (16 pontos) como variáveis circulares ($\sin \theta, \cos \theta$), de modo que N e NNO fiquem próximos;
- *sazonalidade*: $\sin$ e $\cos$ de $2\pi \text{dia}/365,25$;
- *indicadores de ausência* para insolação, evaporação, nebulosidade, pressão e rajada;
- *estação*: *target encoding* [6] com ajuste cruzado (*cross-fitting*), que substitui 49 categorias pela taxa de chuva suavizada da estação.

Tabela II

TESTES DE ESTACIONARIEDADE (TREINO E VALIDAÇÃO, 2008–2015). OS P-VALORES DO KPSS SÃO LIMITADOS À FAIXA DA TABELA DE INTERPOLAÇÃO: 0,100 SIGNIFICA $p \geq 0,10$ E 0,010, $p \leq 0,01$. KPSS: ESTACIONARIEDADE EM NÍVEL; KPSS-CT: ESTACIONARIEDADE EM TORNO DE TENDÊNCIA LINEAR.

	ADF estat.	ADF p-valor	KPSS estat.	KPSS p-valor	KPSS-ct estat.	KPSS-ct p-valor
Série original	-7,451	0,000	0,074	0,100	0,022	0,100
Dessazonalizada (STL)	-11,132	0,000	1,026	0,010	0,117	0,100

Depois disso, as variáveis numéricas são imputadas pela mediana e padronizadas.

Série da regressão. Para Sydney, reindexei o calendário diário, que tem 91 dias sem MaxTemp , e calculei a média semanal (semanas terminadas no domingo), exigindo pelo menos 4 dias válidos. As 12 semanas que não atingem esse mínimo (2,4% da série) foram interpoladas linearmente. A agregação semanal filtra o ruído da escala sinótica (alguns dias), praticamente imprevisível com semanas de antecedência, e realça a dinâmica sazonal. O resultado são 490 semanas (fev/2008 a jun/2017; Fig. 4).

Na série original, o teste ADF [7] rejeita a raiz unitária e o KPSS [8] não rejeita a estacionariedade (Tabela II), o que indica $d = 0$. Na série dessazonalizada, o ADF continua rejeitando a raiz unitária, mas o KPSS de nível rejeita a estacionariedade. Esse conflito é típico de uma série estacionária em torno de uma tendência, o que se confirma com o KPSS com tendência, que não rejeita a estacionariedade ($p \geq 0,10$). Isso aponta uma variação lenta de nível e motiva testar um termo de tendência determinística. A decomposição STL (Fig. 5) mostra sazonalidade dominante, com força $F_S = \max\{0, 1 - \text{Var}(R)/\text{Var}(S+R)\} \approx 0,81$ [9], [10], e tendência fraca ($F_T \approx 0,09$).

C. Modelos de regressão

Os quatro modelos são supervisionados: aprendem, a partir de pares (passado, futuro), uma função $\hat{y}_{t+h} = f(y_{1:t}, t)$. Seja $m = 365,25/7 \approx 52,18$ o período anual em semanas.

(1) SARIMAX com regressão harmônica. Com $m \approx 52$, o polinômio sazonal $(P, D, Q)_{52}$ do SARIMA é caro e instável. Por isso, usei o $\mathbf{X}$ do SARIMAX [10], [11]: K pares de Fourier como regressores exógenos e erros ARMA(p, q):

$$y_t = \beta_0 + \beta_1 t + \sum_{k=1}^K \left[a_k \sin \frac{2\pi kt}{m} + b_k \cos \frac{2\pi kt}{m} \right] + \eta_t, \quad (1)$$

com $\phi(B)\eta_t = \theta(B)\varepsilon_t$ e $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$. Os parâmetros são estimados por máxima verossimilhança exata via filtro de Kalman [12], [13]. Como não há polinômio sazonal, o modelo é, a rigor, uma regressão harmônica com erros ARMA; o nome SARIMAX vem da classe do statsmodels usada no ajuste.

(2) Prophet. Modelo aditivo bayesiano [14]: $y(t) = g(t) + s(t) + \varepsilon_t$, em que g é uma tendência linear por partes, com pontos de mudança sob *prior* de Laplace de escala τ , e $s(t) = \sum_{n=1}^N [a_n \cos(2\pi nt/365,25) + b_n \sin(2\pi nt/365,25)]$, com t em dias e *prior* normal de escala σ_s . A estimação é por MAP no Stan [15].

(3) Decomposição STL + ARIMA. A STL robusta [16] separa $y_t = T_t + S_t + R_t$ por suavizações LOESS iterativas.




Figura 1. Valores ausentes. (a) Percentual por variável. (b) Percentual por estação para as variáveis mais afetadas: as faixas escuras (100%) indicam estações sem o instrumento, ou seja, ausência estrutural, não aleatória.




Figura 2. Matriz de correlação de Pearson; valores com $|r| \geq 0,6$ estão anotados.

Como cada semana do ano tem só cerca de 7 observações no treino, o perfil sazonal $\hat{S}(c)$, com $c = t \bmod 52$, é a média de S_t por posição, suavizada circularmente entre semanas vizinhas. A série dessazonalizada $a_t = y_t - \hat{S}(t \bmod 52)$ é modelada por um ARIMA, e a previsão é $\hat{y}_{t+h} = \hat{a}_{t+h} + \hat{S}((t+h) \bmod 52)$.

(4) Combinação. Média simples das três previsões, $\hat{y}_t^{\text{comb}} =$

$\frac{1}{3}(\hat{y}_t^{\text{SARIMAX}} + \hat{y}_t^{\text{Prophet}} + \hat{y}_t^{\text{STL}})$. Com erros de média zero, seu erro quadrático médio é $\frac{1}{9} \sum_{i,j} \rho_{ij} \sigma_i \sigma_j$, que nunca supera o do pior componente e é menor que o de todos quando os erros têm variâncias parecidas e são pouco correlacionados [17]. Por não estimar pesos, a combinação não sobreajusta. O intervalo de 95% foi aproximado pela média dos limites dos componentes, aproximação conservadora quando $\rho_{ij} < 1$, pois ignora a redução de variância da média.

D. Modelos de classificação

Regressão logística — um GLM com distribuição de Bernoulli e ligação logit [18]: $\Pr(Y = 1 | \mathbf{x}) = \sigma(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})$. Os coeficientes minimizam a log-verossimilhança negativa ponderada com penalidade L2,

$$\min_{\boldsymbol{\beta}} - \sum_i w_{y_i} [y_i \log p_i + (1 - y_i) \log(1 - p_i)] + \frac{1}{2C} \|\boldsymbol{\beta}\|_2^2, \quad (2)$$

com pesos $w_c = n/(2n_c)$ que compensam o desbalanceamento. O termo e^{β_j} é a razão de chances associada a um desvio-padrão do preditor j .

KNN [19], [20]: $\hat{p}(\mathbf{x}) = \sum_{i \in N_k(\mathbf{x})} w_i y_i / \sum w_i$, com $w_i = 1/\|\mathbf{x} - \mathbf{x}_i\|_2$. É não paramétrico, com fronteira local e flexível.

Random Forest [21]: média de B árvores, cada uma treinada em uma amostra *bootstrap* e com sorteio de variáveis em cada nó, o que reduz a correlação entre árvores e, portanto, a variância.

LightGBM [22]–[24]: modelo aditivo $F_M(\mathbf{x}) = \sum_{j=1}^M \eta f_j(\mathbf{x})$, em que cada árvore f_j é ajustada por um passo de Newton, com o gradiente e a hessiana da perda logística avaliados em




Figura 3. Alvo da classificação. (a) Frequência das classes. (b) Proporção de dias seguidos de chuva por mês. (c) Proporção por estação. A linha tracejada é a média global (22,4%).




Figura 4. Temperatura máxima em Sydney: série diária (cinza claro) e média semanal (preto). As faixas indicam os períodos de validação (2015) e de teste (jan/2016 a jun/2017).

F_{j-1} , com crescimento *leaf-wise*, histogramas e regularização L2.

A escolha cobre um modelo linear interpretável (um GLM), um modelo baseado em distância e dois *ensembles* de árvores, aptos a capturar interações não lineares entre umidade, pressão e vento.

III. EXPERIMENTOS E RESULTADOS

Toda a implementação foi feita em Python, com pandas [25], NumPy [26], SciPy [27], statsmodels [13], Prophet [14], scikit-learn [28], LightGBM [22] e Matplotlib [29], com semente fixa (42).

A. Configuração da regressão

A divisão é estritamente temporal: treino de fev/2008 a dez/2014 (360 semanas), validação em 2015 (52) e teste de jan/2016 a jun/2017 (78). Os hiperparâmetros foram escolhidos em grade:

- **SARIMAX**: $K \in \{1, 2, 3, 4, 6\}$, $p, q \in \{0, 1, 2\}$, tendência constante ou linear (90 modelos), selecionados pelo AIC [30], critério baseado na verossimilhança das inovações um passo à frente;

- **Prophet**: $N \in \{3, 5, 10\}$, $\tau \in \{0,001; 0,01; 0,1; 0,5\}$, $\sigma_s \in \{1, 10\}$, selecionados pelo RMSE na validação;
- **STL**: janela sazonal $\in \{7, 13, 25, 53\}$, suavização $\in \{1, 3, 5, 9\}$ e seis especificações ARIMA, selecionadas pelo RMSE na validação.

Os modelos escolhidos (Tabela III) foram retreinados em 2008–2015 e avaliados em dois cenários: (A) **longo prazo**, com uma única previsão para $h = 1, \dots, 78$ semanas; e (B) **um passo à frente**, em que, a cada semana do teste, prevê a seguinte com todas as observações já disponíveis. No cenário B, SARIMAX e STL mantêm os parâmetros e atualizam o estado pelo filtro de Kalman; o Prophet, que não tem estado dinâmico, é retreinado toda semana. As referências mínimas são o ingênuo sazonal, $\hat{y}_{t+h} = y_{t+h-52}$, no cenário A e a persistência, $\hat{y}_{t+1} = y_t$, no cenário B. Por fim, um *backtest* com origem móvel treina até o fim de 2011, 2012, 2013 e 2014 e prevê o ano seguinte inteiro ($h = 52$), sem usar o período de teste. Como 2015 também serviu para escolher os hiperparâmetros, o RMSE desse ano no *backtest* é levemente otimista.

O AIC escolheu ARMA(1,1) com $K = 2$ harmônicos e tendência linear. A especificação de menor RMSE de validação, apenas com Fourier e sem termos ARMA, foi descartada

Tabela III
HIPERPARÂMETROS ESCOLHIDOS E RMSE (°C) NA VALIDAÇÃO (2015), COM OS MODELOS TREINADOS ATÉ 2014.

	Configuração	RMSE val
SARIMAX	ARMA(1,1) + Fourier K=2, tendência=ct	1,63
Prophet	Fourier anual N=3, tau=0.001, sigma_s=10.0	1,54
STL	STL(janela=53), suav.=3 + ARIMA(0,1,1), tendência=n	1,60
Combinado	Média simples de SARIMAX, Prophet e STL	1,56
Ingênuo sazonal	$y(t+h)=y(t+h-52)$; 1 passo: $y(t+1)=y(t)$	2,25




Figura 5. Acima: decomposição STL robusta da série semanal (2008–2015). Abaixo: ACF e PACF da série semanal original, com banda de 95% sob ruído branco; a oscilação com período de 52 semanas reflete a sazonalidade determinística.

porque seus resíduos eram autocorrelacionados (Ljung–Box com $p < 10^{-4}$), o que viola a premissa de ε_t i.i.d. No Prophet, venceram uma tendência quase rígida ($\tau = 0,001$) e $N = 3$; na STL, uma janela sazonal de 53 (sazonalidade praticamente fixa) com ARIMA(0,1,1) no nível, equivalente a uma suavização exponencial simples.

Tabela IV
DESEMPENHO NO TESTE (78 SEMANAS, 2016–2017). EM NEGRITO, O MELHOR VALOR DE CADA COLUNA.

(A) Longo prazo ($h = 1, \dots, 78$)					
	RMSE	MAE	MAPE (%)	R^2	Cob. IC95 (%)
SARIMAX	1,65	1,31	5,49	0,82	93,59
Prophet	1,66	1,33	5,48	0,81	97,44
STL	1,81	1,45	5,93	0,78	93,59
Combinado	1,68	1,34	5,53	0,81	96,15
Ingênuo sazonal	2,12	1,73	7,16	0,70	100,00

(B) Um passo à frente					
	RMSE	MAE	MAPE (%)	R^2	Cob. IC95 (%)
SARIMAX	1,59	1,29	5,40	0,83	94,87
Prophet	1,64	1,35	5,63	0,82	96,15
STL	1,73	1,44	6,03	0,80	92,31
Combinado	1,63	1,34	5,60	0,82	94,87
Persistência	2,03	1,58	6,65	0,72	94,87

Tabela V
Backtest COM ORIGEM MÓVEL: RMSE (°C) AO PREVER CADA ANO INTEIRO ($h = 52$), TREINANDO SÓ COM OS ANOS ANTERIORES.

	2012	2013	2014	2015	Média	DP
SARIMAX	1,36	1,87	1,86	1,63	1,68	0,24
Prophet	1,39	1,78	1,89	1,54	1,65	0,23
STL	1,76	1,81	1,97	1,60	1,78	0,15
Combinado	1,44	1,80	1,89	1,56	1,67	0,21
Ingênuo sazonal	2,69	2,30	2,57	2,25	2,45	0,21

B. Resultados da regressão

As Tabelas IV e V e as Figs. 6 e 7 resumem os resultados. No teste, o SARIMAX teve o menor erro nos dois cenários (RMSE de 1,65 °C e 1,59 °C; R^2 de 0,82 e 0,83), seguido pelo Prophet e pela combinação. Todos superaram as referências ingênuas; o melhor modelo reduziu o RMSE em 22%. As coberturas empíricas dos intervalos de 95% ficaram entre 92% e 97%, coberturas compatíveis com o nível nominal (com 78 semanas independentes, o erro-padrão de uma cobertura de 95% seria de cerca de 2,5 pontos percentuais; como os erros de previsão são autocorrelacionados, a incerteza real é maior).

Significância. O teste de Diebold–Mariano [31], com correção de pequenas amostras [32] aplicada aos erros um passo à frente (Tabela VI), mostra que, a 5% e sem correção para múltiplas comparações, o SARIMAX é significativamente melhor que a persistência ($p = 0,016$) e que a STL ($p = 0,036$),




Figura 6. Previsões de longo prazo ($h = 1$ a 78 semanas) a partir do fim de 2015, com intervalos de 95%. Em cinza, o final do treino; em preto, o observado no teste.




Figura 7. Cenário um passo à frente no teste. Acima: previsões contra o observado. Abaixo: erro absoluto acumulado, em que curvas mais baixas indicam modelos melhores e a inclinação mostra onde cada um perde, como no verão quente de 2016/17.

mas não se distingue do Prophet ($p = 0,20$) nem da combinação ($p = 0,16$). Com correção de Bonferroni para as quatro comparações ($\alpha = 0,0125$), nenhuma diferença seria significativa. O

Tabela VI
TESTE DE DIEBOLD–MARIANO: SARIMAX CONTRA OS DEMAIS MODELOS (ERROS UM PASSO À FRENTE). DM < 0 FAVORECE O SARIMAX.

	DM	p-valor
Prophet	−1,298	0,198
STL	−2,140	0,036
Combinado	−1,410	0,163
Persistência	−2,453	0,016

backtest confirma esse empate técnico: as médias dos quatro modelos ficam entre 1,65 e 1,78 °C, contra 2,45 °C do ingênuo, e o ranking muda de ano para ano. O Prophet tem a menor média, e a combinação, a segunda menor, com desvio-padrão inferior ao do SARIMAX.

Análise de resíduos. A Tabela VII e a Fig. 8 avaliam as premissas usando os resíduos dentro da amostra, sem o primeiro ano. No SARIMAX, não se rejeita a média nula ($p = 0,89$) nem se detecta autocorrelação (Ljung–Box [33] com 10 e 52 defasagens: $p = 0,60$ e $0,26$) ou heterocedasticidade condicional (ARCH-LM [34]: $p = 0,75$). A normalidade é rejeitada (Jarque–Bera [35] e Shapiro–Wilk [36]): o gráfico Q-Q mostra centro gaussiano e alguns pontos na cauda direita, correspondentes a ondas de calor como a de fevereiro de 2011, cuja semana teve média de 34,9 °C. Com $n = 360$ semanas, os testes detectam desvios pequenos, e o efeito prático é modesto (cobertura de 93,6% no teste). Já os resíduos do Prophet são autocorrelacionados ($p < 0,001$): o modelo descreve apenas tendência e sazonalidade e deixa a persistência de curto prazo

Tabela VII
DIAGNÓSTICO DOS RESÍDUOS DENTRO DA AMOSTRA (2009–2015): MÉDIA
E P-VALORES DOS TESTES T (MÉDIA NULA), LJUNG–BOX COM 10 E 52
DEFASAGENS (LB), JARQUE–BERA (JB), SHAPIRO–WILK (SW) E
ARCH-LM COM 10 DEFASAGENS.

	Média	p_t	LB(10)	LB(52)	JB	SW	ARCH(10)
SARIMAX	0,013	0,886	0,595	0,260	0,000	0,001	0,747
Prophet	−0,027	0,761	0,000	0,000	0,000	0,002	0,925
STL	0,023	0,797	0,600	0,052	0,000	0,000	0,942
Combinado	0,003	0,976	0,596	0,162	0,000	0,000	0,942

no erro.

C. Configuração da classificação

Usei um *holdout temporal*: treino de nov/2007 a dez/2015 (116.219 dias-estação, 22,3% positivos) e teste de jan/2016 a jun/2017 (25.974; 22,9% positivos). Imputação, *target encoding* e padronização ficam dentro de um Pipeline do scikit-learn, reajustado em cada dobra. Os hiperparâmetros foram buscados com 3 dobras estratificadas, maximizando a ROC-AUC (Tabela VIII). Para KNN, Random Forest e LightGBM, a busca usou uma amostra estratificada de 40 mil linhas, por custo computacional. A robustez foi medida com **validação cruzada estratificada de 5 dobras** no treino completo. Os pesos de classe (*balanced*) foram aplicados à logística, à Random Forest e ao LightGBM. Para cada modelo, o limiar de decisão foi o que maximiza o F1 nas previsões *fora da dobra* do treino; só depois ele foi aplicado ao teste.

D. Resultados da classificação

Validação cruzada. A variação entre dobras é pequena (desvio-padrão $\leq 0,003$ na AUC), e o ordenamento LightGBM > Random Forest > KNN > logística é o mesmo em todas as dobras (Tabela IX e Fig. 11). Com limiar de 0,5, KNN e Random Forest têm revocação baixa (0,46 e 0,50): o KNN não usa pesos de classe, e a Random Forest, mesmo com pesos, concentra as probabilidades da classe minoritária abaixo de 0,5. Por isso o ajuste do limiar (para 0,28 e 0,32, respectivamente) é essencial.

Teste temporal. O LightGBM venceu em todas as métricas de discriminação (Tabela X): ROC-AUC de 0,889, com IC 95% por *bootstrap* [37] de [0,884; 0,893], PR-AUC de 0,752 e F1 de 0,674. A Random Forest ficou em segundo lugar (AUC de 0,880 [0,875; 0,884]). Os intervalos desses dois modelos ficam acima das AUCs da logística (0,862) e do KNN (0,867); como todos são avaliados no mesmo teste, um teste pareado, como o de DeLong [38], seria a comparação mais rigorosa. As curvas ROC e precisão–revocação aparecem na Fig. 9. Sob desbalanceamento, a curva PR é mais informativa [39]: a linha de base é a prevalência (0,23), e a vantagem do *boosting* fica mais nítida. As AUCs de teste são 0,01–0,02 menores que as da validação cruzada, provavelmente porque o teste está no futuro e as dobras aleatórias misturam dias vizinhos entre treino e validação.

Matriz de confusão. Com o limiar ótimo de 0,57, o LightGBM identifica 4.207 dos 5.946 dias com chuva (revocação de

70,8%), acerta 64,3% das vezes em que prevê chuva (precisão) e classifica corretamente 88,3% dos dias secos (Fig. 13). O limiar é uma decisão de custo: com 0,50, a revocação sobe para 76,0%, ao preço de 705 alarmes falsos a mais.

Interpretação. A importância por permutação [21] do LightGBM e os coeficientes padronizados da logística (Fig. 10) concordam no topo: Humidity3pm e WindGustSpeed dominam, como esperado fisicamente, pois ar úmido à tarde e rajadas fortes acompanham a chegada de sistemas frontais; ambas, além disso, são medidas dentro da janela do alvo (Seção II). No LightGBM seguem a estação (Location), a pressão das 15h, a insolação e duas tendências barométricas criadas na engenharia de atributos, dPressure_24h e dPressure_9a15. Na logística, dPressure_24h tem coeficiente negativo: pressão em queda aumenta a chance de chuva. Como a permutação subestima variáveis correlacionadas entre si (por exemplo, Humidity3pm e dHumidity_9a15), esse ranking é indicativo. Na logística, um desvio-padrão a mais de rajada multiplica a chance de chuva por 1,88, e um a mais de umidade às 15h, por 1,65.

Calibração. A logística e o LightGBM, treinados com pesos de classe, superestimam a probabilidade de chuva (Fig. 12), efeito esperado da reponderação. A Random Forest, embora também ponderada, fica acima da diagonal, como o KNN, ou seja, subestima a probabilidade, pois a média dos votos das árvores comprime as probabilidades, o mesmo efeito que leva seu limiar ótimo a 0,32. Isso não afeta a AUC nem o F1 com limiar ajustado, mas explica por que o escore de Brier [40] do LightGBM (0,122) é pior que o da Random Forest (0,108).

IV. DISCUSSÃO E CONCLUSÃO

Regressão. O SARIMAX com harmônicos e erros ARMA foi o melhor modelo no teste por três motivos: (i) a série é dominada por uma sazonalidade suave, que dois harmônicos descrevem com poucos parâmetros; (ii) os erros ARMA absorvem a persistência de curto prazo e deixam resíduos sem autocorrelação detectável, o que rende ganho no cenário de um passo à frente; e (iii) a estimação por máxima verossimilhança, com seleção pelo AIC, controla a complexidade. Prophet e SARIMAX convergem para a mesma “climatologia” no longo prazo, e as diferenças entre eles não são estatisticamente significativas. A STL foi prejudicada pelo perfil sazonal estimado semana a semana, mais ruidoso, e pelo índice $c = t \bmod 52$: com período de 52,18 semanas, a fase do perfil desliza cerca de uma semana a cada 5,6 anos. A combinação não superou o melhor modelo porque os erros dos componentes são muito correlacionados (todos erram juntos nas ondas de calor), mas foi a segunda opção mais estável no *backtest*. Na prática, ela continua sendo uma escolha defensiva sensata quando não se sabe de antemão qual modelo vencerá.

Classificação. Os *ensembles* de árvores superaram os modelos linear e baseado em distância porque capturam interações (por exemplo, umidade alta e pressão em queda) e não linearidades sem especificação manual. O *boosting*, ao corrigir sequencialmente os erros, foi o mais eficiente. A logística,




Figura 8. Resíduos do melhor modelo (SARIMAX). (a) Resíduos dentro da amostra (azul) e erros de previsão no teste (laranja). (b) Histograma com a normal ajustada. (c) Gráfico Q-Q normal. (d) ACF dos resíduos com banda de 95%.

Tabela VIII
HIPERPARÂMETROS SELECIONADOS (BUSCA COM 3 DOBRAS, ROC-AUC).

	Melhores hiperparâmetros	AUC (busca)	Amostra
Regressão Logística	C=0.1	0,8730	116 mil
KNN	k=61, pesos=distance	0,8754	40 mil
Random Forest	min_folha=1, max_feat=0.4, prof.=None	0,8873	40 mil
LightGBM	lambda=1.0, folhas=127, árvores=1000, min_filhos=50, eta=0.02, colsample=0.6	0,8972	40 mil




Figura 9. (a) Curvas ROC e (b) curvas precisão-revoação no conjunto de teste. Os pontos marcam o limiar escolhido para cada modelo; as linhas pontilhadas são o classificador aleatório e a prevalência.

embora inferior, continua valiosa pela interpretabilidade e confirma a física do problema.

Limitações. (i) A regressão usa uma única estação e nenhuma covariável climática de grande escala (por exemplo,




Figura 10. (a) Importância por permutação no teste (queda de ROC-AUC, média $\pm$ desvio em 5 repetições) do LightGBM. (b) Os 15 maiores coeficientes da regressão logística, sobre preditores padronizados: azul aumenta e laranja reduz a probabilidade de chuva.

Tabela IX
VALIDAÇÃO CRUZADA ESTRATIFICADA DE 5 DOBRAS NO TREINO (MÉDIA $\pm$ DESVIO-PADRÃO; MÉTRICAS DE LIMAR COM CORTE EM 0,5).

	ROC-AUC	PR-AUC	F1	Revocação	Precisão	Acurácia bal.
Regressão Logística	0,873 $\pm$ 0,003	0,702 $\pm$ 0,006	0,628 $\pm$ 0,004	0,774 $\pm$ 0,009	0,528 $\pm$ 0,004	0,788 $\pm$ 0,004
KNN	0,884 $\pm$ 0,002	0,728 $\pm$ 0,003	0,579 $\pm$ 0,003	0,456 $\pm$ 0,005	0,796 $\pm$ 0,004	0,711 $\pm$ 0,002
Random Forest	0,898 $\pm$ 0,002	0,748 $\pm$ 0,005	0,614 $\pm$ 0,003	0,503 $\pm$ 0,005	0,788 $\pm$ 0,007	0,732 $\pm$ 0,002
LightGBM	0,908 $\pm$ 0,002	0,776 $\pm$ 0,005	0,690 $\pm$ 0,005	0,767 $\pm$ 0,004	0,627 $\pm$ 0,009	0,818 $\pm$ 0,002




Figura 11. ROC-AUC e F1 em cada uma das 5 dobras; o traço preto marca a média.

Tabela X
DESEMPENHO NO TESTE TEMPORAL (2016–2017), COM LIMAR (LIM.) ESCOLHIDO FORA DA DOBRA. ACUR.: ACURÁCIA; PREC.: PRECISÃO; REV.: REVOCAÇÃO; AUC: ÁREA SOB A CURVA ROC; AP: PRECISÃO MÉDIA (PR-AUC); Brier: ERRO QUADRÁTICO DAS PROBABILIDADES (MENOR É MELHOR).

	Lim.	Acur.	Prec.	Rev.	F1	AUC	AP	Brier
Logística	0,604	0,824	0,606	0,668	0,635	0,862	0,691	0,147
KNN	0,282	0,825	0,603	0,688	0,642	0,867	0,711	0,113
Random Forest	0,317	0,837	0,630	0,697	0,662	0,880	0,725	0,108
LightGBM	0,571	0,843	0,643	0,708	0,674	0,889	0,752	0,122




Figura 12. Curvas de confiabilidade no teste (10 bins por quantil). Pontos abaixo da diagonal indicam probabilidades superestimadas.

ENSO/SOI), que poderiam melhorar o longo prazo. (ii) A cauda direita dos resíduos não é gaussiana, o que sugere intervalos por *bootstrap* ou erros t-Student. (iii) A validação cruzada com dobras aleatórias, usada também na busca de hiperparâmetros e na escolha do limiar, é levemente otimista; validação por blocos temporais ou agrupada por data seria mais fiel. O mesmo vale para o *bootstrap* dos intervalos de AUC, que trata como




Figura 13. Matriz de confusão do LightGBM no teste: contagens e percentuais por classe real, com limiar de 0,50 (esquerda) e com o limiar que maximiza o F1 fora da dobra (direita).

independentes os dias-estação de uma mesma data. (iv) As probabilidades do LightGBM precisam de calibração (Platt [41] ou isotônica [42]). (v) Parte dos preditores é medida dentro da janela do alvo, o que torna a tarefa em parte *nowcasting*. (vi) Os dados terminam em 2017.

Pronto para produção? Os dois modelos vencedores são reprodutíveis, rápidos e superam com folga as referências. Antes de uso operacional, porém, seria preciso retreiná-los com dados recentes do BoM, calibrar as probabilidades, definir o limiar a partir de uma matriz de custos real e monitorar a deriva causada pelas mudanças climáticas. Como prova de conceito, os resultados são sólidos; como sistema de alerta, ainda precisam dessas melhorias.

REFERÊNCIAS

- [1] E. N. Lorenz, "Deterministic nonperiodic flow," *Journal of the Atmospheric Sciences*, vol. 20, no. 2, pp. 130–141, 1963.
- [2] J. Young and A. Young, "Rain in Australia: Predict next-day rain in Australia," Kaggle, 2020, disponível em: <https://www.kaggle.com/datasets/jshyphg/weather-dataset-rattle-package>. Acesso em: 4 out. 2026.
- [3] Bureau of Meteorology, "Climate data online," Commonwealth of Australia, disponível em: <http://www.bom.gov.au/climate/data/>. Acesso em: 4 out. 2026.
- [4] G. J. Williams, *Data Mining with Rattle and R: The Art of Excavating Data for Knowledge Discovery*. New York: Springer, 2011.
- [5] J. W. Tukey, *Exploratory Data Analysis*. Reading: Addison-Wesley, 1977.
- [6] D. Micci-Barreca, "A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems," *ACM SIGKDD Explorations Newsletter*, vol. 3, no. 1, pp. 27–32, 2001.
- [7] D. A. Dickey and W. A. Fuller, "Distribution of the estimators for autoregressive time series with a unit root," *Journal of the American Statistical Association*, vol. 74, no. 366a, pp. 427–431, 1979.
- [8] D. Kwiatkowski, P. C. B. Phillips, P. Schmidt, and Y. Shin, "Testing the null hypothesis of stationarity against the alternative of a unit root," *Journal of Econometrics*, vol. 54, no. 1–3, pp. 159–178, 1992.
- [9] X. Wang, K. Smith, and R. J. Hyndman, "Characteristic-based clustering for time series data," *Data Mining and Knowledge Discovery*, vol. 13, no. 3, pp. 335–364, 2006.
- [10] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne: OTexts, 2021, disponível em: <https://otexts.com/fpp3/>.
- [11] G. E. P. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th ed. Hoboken: Wiley, 2015.
- [12] J. Durbin and S. J. Koopman, *Time Series Analysis by State Space Methods*, 2nd ed. Oxford: Oxford University Press, 2012.
- [13] S. Seabold and J. Perktold, "statsmodels: Econometric and statistical modeling with Python," in *Proceedings of the 9th Python in Science Conference*, 2010, pp. 92–96.
- [14] S. J. Taylor and B. Letham, "Forecasting at scale," *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018.
- [15] B. Carpenter, A. Gelman, M. D. Hoffman, D. Lee, B. Goodrich, M. Betancourt, M. Brubaker, J. Guo, P. Li, and A. Riddell, "Stan: A probabilistic programming language," *Journal of Statistical Software*, vol. 76, no. 1, pp. 1–32, 2017.
- [16] R. B. Cleveland, W. S. Cleveland, J. E. McRae, and I. Terpenning, "STL: A seasonal-trend decomposition procedure based on loess," *Journal of Official Statistics*, vol. 6, no. 1, pp. 3–73, 1990.
- [17] J. M. Bates and C. W. J. Granger, "The combination of forecasts," *Operational Research Quarterly*, vol. 20, no. 4, pp. 451–468, 1969.
- [18] J. A. Nelder and R. W. M. Wedderburn, "Generalized linear models," *Journal of the Royal Statistical Society. Series A*, vol. 135, no. 3, pp. 370–384, 1972.
- [19] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.
- [20] S. A. Dudani, "The distance-weighted k-nearest-neighbor rule," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. SMC-6, no. 4, pp. 325–327, 1976.
- [21] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [22] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30*, 2017, pp. 3146–3154.
- [23] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [24] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
- [25] W. McKinney, "Data structures for statistical computing in Python," in *Proceedings of the 9th Python in Science Conference*, 2010, pp. 56–61.
- [26] C. R. Harris et al., "Array programming with NumPy," *Nature*, vol. 585, no. 7825, pp. 357–362, 2020.
- [27] P. Virtanen et al., "SciPy 1.0: Fundamental algorithms for scientific computing in Python," *Nature Methods*, vol. 17, pp. 261–272, 2020.
- [28] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [29] J. D. Hunter, "Matplotlib: A 2D graphics environment," *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.
- [30] H. Akaike, "A new look at the statistical model identification," *IEEE Transactions on Automatic Control*, vol. 19, no. 6, pp. 716–723, 1974.
- [31] F. X. Diebold and R. S. Mariano, "Comparing predictive accuracy," *Journal of Business & Economic Statistics*, vol. 13, no. 3, pp. 253–263, 1995.
- [32] D. Harvey, S. Leybourne, and P. Newbold, "Testing the equality of prediction mean squared errors," *International Journal of Forecasting*, vol. 13, no. 2, pp. 281–291, 1997.
- [33] G. M. Ljung and G. E. P. Box, "On a measure of lack of fit in time series models," *Biometrika*, vol. 65, no. 2, pp. 297–303, 1978.
- [34] R. F. Engle, "Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation," *Econometrica*, vol. 50, no. 4, pp. 987–1007, 1982.
- [35] C. M. Jarque and A. K. Bera, "Efficient tests for normality, homoscedasticity and serial independence of regression residuals," *Economics Letters*, vol. 6, no. 3, pp. 255–259, 1980.
- [36] S. S. Shapiro and M. B. Wilk, "An analysis of variance test for normality (complete samples)," *Biometrika*, vol. 52, no. 3–4, pp. 591–611, 1965.
- [37] B. Efron, "Bootstrap methods: Another look at the jackknife," *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.
- [38] E. R. DeLong, D. M. DeLong, and D. L. Clarke-Pearson, "Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach," *Biometrics*, vol. 44, no. 3, pp. 837–845, 1988.
- [39] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLoS ONE*, vol. 10, no. 3, p. e0118432, 2015.

- [40] G. W. Brier, "Verification of forecasts expressed in terms of probability," *Monthly Weather Review*, vol. 78, no. 1, pp. 1–3, 1950.
- [41] J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*, A. J. Smola, P. Bartlett, B. Schölkopf, and D. Schuurmans, Eds. Cambridge, MA: MIT Press, 1999, pp. 61–74.
- [42] B. Zadrozny and C. Elkan, "Transforming classifier scores into accurate multiclass probability estimates," in *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2002, pp. 694–699.